

超图检索器中的替代最短路径监督： 结构审计与受控实验

杨金名

2026 年 9 月

1 研究问题

HyperRAG 将多元事实表示为超图，并用选中的主题实体到答案实体最短路径构造检索监督 [4]。当图中存在多条等长最短路径时，程序只选中其中一条；另一条路径上的转移仍可能进入负例采样。于是，同样能够沿全局最短路径到达答案的候选，可能仅因没有被路径选择程序抽中而受到惩罚。

本文回答两个可检验的问题。第一，这类争议负例在官方 WikiTopics 结构化数据中是否足够常见？第二，在候选、特征、数据划分和优化设置全部固定时，把争议候选标负、忽略或标正，会怎样改变检索与答案可达性？我们把随机丢弃等量负例作为机制对照，以区分路径信息与单纯减少负例数量的作用。

本文不把最短路径等同于语义证据。最短路径条件只能证明一个转移处于观测图中的某条最短答案路径，不能证明它表达了问题要求的关系。因此，策略 2 采用“忽略”而非“标正”；策略 3 则用于检验更激进的全部最短路径监督。类似的最短路径弱监督见于 PullNet 和 SubgraphRAG[3, 5]，而近期工作也指出结构最短与语义充分并不等价 [1, 2]。

2 定义与监督策略

设知识超图为 $\mathcal{H} = (V, \mathcal{F})$ 。其关联图 G_I 的节点由实体和超边共同组成；实体 v 经超边 f 到实体 u 的一次移动记为 (v, f, u) 。这只是超图中的有向候选转移，不把原始多元事实改写成二元关系。在关联图中，该转移的长度为 2。

对问题 q ，令 S_q 为主题实体集合， A_q 为正确答案实体集合。候选转移 (v, f, u) 若满足

$$\exists s \in S_q, a \in A_q : d_I(s, v) + 2 + d_I(u, a) = d_I(s, a), \quad (1)$$

则称其为路径一致候选。

命题 1. 在无权关联图中，有效转移 (v, f, u) 位于某条 s 到 a 的最短路径上，当且仅当它满足式(1)。

证明. 若等式成立，将 s 到 v 的最短路径、转移 $v \rightarrow f \rightarrow u$ 与 u 到 a 的最短路径拼接，长度恰为 $d_I(s, a)$ 。反之，最短路径的前缀和后缀也必须为最短路径，按该转移分解路径长度即得等式。□

在每个共享采样种子内，四个实验臂使用完全相同的固定候选：

策略 1 程序选中的路径转移标正，其余采样候选标负。这是公开流程对应的基线。

策略 2 选中路径转移仍标正；满足式(1)、但未被选中的采样候选不参与损失；其余候选仍标负。

策略 3 选中路径及其他最短路径转移均标正，其余候选标负。

随机丢弃

对每个问题随机屏蔽与策略 2 等量的负例，但不使用距离信息。

3 案例分析

考虑问题“某研究员所在团队研发的药物可以治疗哪种疾病？”。主题实体为研究员甲，答案为疾病丙。图中存在两条三跳路径：

研究员甲 → 实验室乙 → 药物甲 → 疾病丙，
研究员甲 → 项目丁 → 药物乙 → 疾病丙。

假设程序选择第一条路径，第二条路径的第一个转移便可能进入负例池。由于第二条路径与第一条等长，它满足式(1)。策略 1 把该转移标负，策略 2 忽略它，策略 3 把它标正。

这个例子也说明策略 2 为何不是策略 3 的改名：第二条路径虽然结构上最短，但“参与项目-项目产出药物”未必准确表达问题中的“所在团队研发”。忽略表示暂不判断；标正则加入了更强的语义假设。随机丢弃对照进一步判断策略 2 的变化是否真的来自路径信息。

4 数据与实现

4.1 结构审计

我们使用官方 WikiTopics_QE 的 11 个领域。对每个领域读取训练图、三跳查询、困难答案和原始映射；按照公开的知识图谱到文本规则，将同一头实体的外向事实聚合为多元超边。作者没有发布最终 GraphML，故这里是基于官方整数图的确定性结构重建，而非原运行产物的字节级复原。对每个问题重建单条最短路径正例与引导子图，再从同一候选池复现均衡负采样。等长路径按固定字典序择一；原代码则会受 GraphML 节点插入顺序影响。审计使用共享随机种子 42-46，同时报告采样前候选池发生率和实际采样负例发生率。

最短路径判定不枚举所有路径。实现从主题实体计算距离层，得到最短路径有向无环图，再由可达答案反向标记；判断每个候选的时间为常数。高元超边的候选总数采用组合计数，避免物化二次规模的转移集合。门槛 A 的玩具图测试覆盖等长分支、多主题多答案、有向性、不连通节点和高元超边。

4.2 门槛 C 的结构化代理实验

公开仓库未提供论文训练所使用的最终 GraphML 与预训练文本表示，服务器上也没有相应模型缓存。因此，结构审计与门槛 C 都不冒充原版端到端 HyperRAG 复现，而是使用官方整数图构造结构化代理实验。模型输入只包含实体标识、查询关系、超边关系集合及不依赖标签的结构数值特征；共享嵌入经多层感知机输出候选分数。四个实验臂只改变标签或损失掩码。

问题按固定种子划分为训练、验证和测试集，防止同一问题的候选跨集合泄漏。每个实验臂使用五个共享训练种子。模型以二元交叉熵训练，验证损失早停。主要指标为在得分最高的 10 个转移中，能否从主题实体到达任一答案实体；同时报告全部最短路径召回率和选中路径的逐问题精确率-召回率曲线下面积。

4.3 统计与阶段门槛

门槛 B 预先设为：全局实际采样争议率达到 1%，或任一领域达到 1%，才进入训练。门槛 C 的主比较为策略 2 相对策略 1 和随机丢弃的答案可达率 @10。先对每个问题的五个共享种子等权平均，再以唯一问题为配对单位执行 10,000 次配对自助法；两个比较的 95% 区间下界都必须大于零。同时，策略 2 相对策略 1 的选中路径精确率-召回率曲线下面积下降不得超过 1 个百分点。只有三个条件同时成立，才扩展到门槛 D。逐种子的配对差值另外保留在机器可读汇总中。

5 结果

5.1 争议负例确实进入训练采样

审计覆盖 11 个领域、90,000 个三跳训练问题。完整候选池共有 872,576,411,856 个候选，其中 42,926,111 个为未选中的路径一致候选，占 0.005%。五个种子合计采样 10,156,714 个负例，其中 586,117 个存在争议，占 5.77%。候选池比例与实际采样比例不同，说明只看完整图中的组合数量不足以推断监督噪声。

领域	问题数	候选池争议率	采样争议率（均值 ± 标准差，百分点）
组织	4,000	2.60%	11.67% ± 0.09
教育	10,000	0.58%	9.33% ± 0.13
奖项	10,000	2.26%	8.22% ± 0.03
科学	10,000	0.07%	6.74% ± 0.05
基础设施	10,000	0.16%	6.32% ± 0.06
健康	10,000	0.05%	4.85% ± 0.04
艺术	10,000	0.006%	4.06% ± 0.04
生物分类	8,000	0.002%	3.26% ± 0.04
地理	4,000	0.004%	2.32% ± 0.06
人物	10,000	0.06%	2.02% ± 0.02
体育	4,000	0.004%	1.19% ± 0.03

表 1: 11 个 WikiTopics 领域的结构审计。采样统计使用种子 42–46。




图 1: 候选池与实际采样负例中的争议比例。虚线为预先设定的 1% 门槛。

门槛 B 的自动判定为“继续门槛 C”。该判定仅说明现象具有进入受控训练的规模，不表示策略 2 一定有效。

5.2 四种监督处理的受控比较

实验臂	答案可达率 @10	全部最短路径召回率 @10	选中路径曲线下面积
策略 1	82.93 $\pm$ 0.44	72.88 $\pm$ 0.04	96.05 $\pm$ 0.27
策略 2	91.33 $\pm$ 1.04	72.92 $\pm$ 0.04	94.73 $\pm$ 0.21
随机丢弃	83.93 $\pm$ 0.82	72.89 $\pm$ 0.05	95.91 $\pm$ 0.28
策略 3	93.60 $\pm$ 0.53	72.91 $\pm$ 0.02	94.07 $\pm$ 0.31

表 2: 教育领域结构化代理实验的五种子均值 $\pm$ 标准差, 表内均为百分数。




图 2: 门槛 C 四个实验臂的主要结果。误差线表示五个随机种子的标准差。

策略 2 相对策略 1 的答案可达率 @10 配对差为 8.40 个百分点, 95% 配对自助法区间为 [7.28, 9.59], 共 1,497 个问题配对。相对随机丢弃的差为 7.40 个百分点, 区间为 [6.35, 8.51], 共 1,497 个问题配对。策略 2 相对策略 1 的选中路径曲线下面积差为 -1.32 个百分点。

表2呈现出清楚的权衡: 随机丢弃只比策略 1 略高, 而策略 2 的答案可达率明显高于二者, 说明变化不能仅由负例数量减少解释; 策略 3 的答案可达率最高, 表明更积极的最短路径监督进一步扩大了结构覆盖。另一方面, 四个实验臂的全部最短路径召回率 @10 几乎相同, 而策略 2 和策略 3 的选中路径曲线下面积依次降低。也就是说, 更宽的结构覆盖没有转化为对原选中证据排序的同步改善。

预注册条件没有同时满足, 门槛 C 判定为“不扩展完整训练”。因此, 本研究按计划停止跨领域完整重训练。这个停止规则避免在观察教育领域结果后改变主要指标、筛选有利种子或扩大计算规模。

6 讨论

结构审计回答了“错误监督是否真实存在”, 但它不能单独回答“删除这些监督是否改善模型”。门槛 C 进一步固定候选与特征, 并加入随机丢弃对照, 使策略 2 与单纯类别比例变化可区分。实验没有达到扩展标准; 因此, 不能仅凭争议负例比例较高就声称保守屏蔽优于公开基线。

本文有四项边界。第一，审计和门槛 C 都是官方结构数据上的确定性重建，不包含未发布的 GraphML、文本编码器和生成器，因而不能报告端到端答案精确匹配率。第二，原 GraphML 的节点插入顺序未知，等长路径择一可能改变哪些候选被称为“未选中”；本文固定字典序以保证可复现，但没有声称复原原运行的择一路径。第三，路径一致是相对于观测图的结构性质；缺失边和伪边会分别拉长或缩短距离。第四，提案中的双人盲法语义标注需要独立人工标注者，本轮计算实验未获得该资源，因而没有把单个模型的判断伪装成人类一致性结果。本文对“语义有用证据占比”不作数值结论。

7 结论

本文把替代最短路径监督拆成发生率审计与受控因果比较。实现使用全局主题-答案成对距离，而不是较宽松的局部降距条件；策略 1、策略 2、策略 3 和随机丢弃共享候选、划分和特征。结果表明，争议候选会进入实际负采样，足以触发预设训练门槛。然而，策略 2 没有同时满足相对策略 1、相对随机丢弃和精度保护三项条件，故当前证据不支持把它作为 HyperRAG 的有效改进。

可复现性说明

代码采用模块化目录，结构审计、数据准备、四臂训练、六卡调度、配对统计和绘图彼此分离。所有代码通过 GitHub 研究分支同步；服务器运行产物保留在独立实验目录。实验环境为 Python 3.11.15、PyTorch 2.2.2 与 CUDA 12.1，训练并发使用 6 张 24GB 的 RTX 3090。门槛 A 由 41 项单元测试覆盖，门槛 B 与门槛 C 的判定均由聚合脚本从原始运行结果自动生成，论文表格中的数字再由同一汇总文件生成，避免手工转录。

参考文献

- [1] Alberto Cattaneo, Carlo Luschi, and Daniel Justus. Ground-truth subgraphs for better training and evaluation of knowledge graph augmented llms, 2025. URL <https://arxiv.org/abs/2511.04473>.
- [2] Shengxiang Gao, Chao Lei, Jey Han Lau, and Jianzhong Qi. PathISE: Learning informative path supervision for knowledge graph question answering, 2026. URL <https://arxiv.org/abs/2605.10791>.
- [3] Mufei Li, Siqi Miao, and Pan Li. Simple is effective: The roles of graphs and large language models in knowledge-graph-based retrieval-augmented generation. In *International Conference on Learning Representations*, 2025. URL <https://arxiv.org/abs/2410.20724>.
- [4] Wen-Sheng Lien, Yu-Kai Chan, Hao-Lung Hsiao, Bo-Kai Ruan, Meng-Fen Chiang, Chien-An Chen, Yi-Ren Yeh, and Hong-Han Shuai. HyperRAG: Reasoning n-ary facts over hypergraphs for retrieval augmented generation. In *Proceedings of the ACM Web Conference 2026*, pages 2465–2476, 2026. doi: 10.1145/3774904.3792710. URL <https://doi.org/10.1145/3774904.3792710>.
- [5] Haitian Sun, Tania Bedrax-Weiss, and William W. Cohen. PullNet: Open domain question answering with iterative retrieval on knowledge bases and text. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing*, pages 2380–2390, 2019. doi: 10.18653/v1/D19-1242. URL <https://doi.org/10.18653/v1/D19-1242>.