

未被选中的路径并非都是负例：重新审视超图检索中的路径监督

Anonymous Author(s)

CCS Concepts

• Information systems → Retrieval models and ranking; Question answering.

Keywords

超图检索, 路径监督, 负采样, 弱监督, 检索增强生成

ACM Reference Format:

Anonymous Author(s). 2027. 未被选中的路径并非都是负例：重新审视超图检索中的路径监督. In *Proceedings of The ACM Web Conference 2027* (WWW '27). ACM, New York, NY, USA, 6 pages. <https://doi.org/10.1145/nnnnnnn.nnnnnnn>

1 引言

检索增强生成 (retrieval-augmented generation, RAG) 把外部证据检索与生成模型结合, 使知识更新、证据追踪和长尾事实访问不再完全依赖参数记忆 [9]。当知识以图或超图组织时, 检索器还需要从巨大的结构空间中找出能够连接问题实体与答案实体的紧凑证据子图 [6, 11–13]。然而, 基准通常只给出问题和最终答案, 而不提供逐步检索标签。一个常用的弱监督做法是: 为每个可达的主题实体–答案实体对选择一条最短路径, 将所选路径上的转移作为正例, 再从路径引导的候选子图中采样负例。

这一过程把“未被所选路径包含”近似成“与答案无关”。问题在于最短路径可能不唯一。某个未进入所选路径的候选转移, 仍可能位于另一条等长的完整最短答案路径上; 如果它同时被负采样器选中, 训练目标便会对同一结构事实给出相冲突的信号: 它既具有完整最短答案路径成员资格, 又被当作确定负例压低。本文称这类实际采样到的候选为路径一致负例 (*Path-consistent Negative*)。这是结构性质, 而非语义判断: 本文不声称它一定是语义正例或人工确认的错误负例。

我们研究一个最小干预问题: 在候选、文本与结构特征、模型架构、优化器和推理过程全部保持不变时, 是否应降低这类冲突负例的监督强度? 我们只引入一个领域级权重 $\lambda \in [0, 1]$ 。 $\lambda = 1.00$ 精确恢复原训练目标, $\lambda = 0.00$ 屏蔽冲突负例, 中间值保留较弱的负向约束。每个领域仅用验证集 Answer-Path MRR 从预先冻结的网格中选择 λ_D^* ; 测试集在选择完成前不可访问。

实验完全隔离检索器, 不调用任何生成式大语言模型, 也不进行人工标注或 LLM Judge。我们复用 HyperRAG 官方 HyperRetriever 的 GTE、DDE 和两层 MLP, 在由 WikiTopics 结构化数据确定性构建的超图上开展实验。该设置不是对端到端 HyperRAG 问答质量的完整复现, 而是对其检索训练监督的受控研究。

本文贡献如下:

- 给出只作用于实际采样负例的完整主题–答案最短路径判据, 并在 WikiTopics 的 11 个领域中量化这种监督冲突;
- 提出不增加模型参数、不改变候选和推理过程的最小降权目标, 并让验证集实验决定最终采用硬屏蔽还是软加权;

- 通过等量随机降权对照和最短路径选择敏感性实验, 分别检验收益是否来自路径定位信息, 以及方法是否降低了单路径监督的任意性。

2 相关工作

2.1 RAG 与图结构检索

稠密检索和 RAG 奠定了以可学习检索器访问外部证据的基础 [7, 9]。面向知识图谱问答, PullNet 迭代扩展与问题相关的子图 [12], 可微子图检索进一步研究答案覆盖与噪声控制之间的关系 [13]。G-Retriever 将文本属性图上的证据选择表述为结构优化问题 [6], SubgraphRAG 重新考察图结构与语言模型在知识图谱 RAG 中的分工 [10]。HyperRAG 使用超图保留不宜拆成独立二元边的高元事实, 并以路径派生标签训练 HyperRetriever [11]。本文不增加新的检索骨干, 而是研究这种路径派生监督本身。

2.2 不完整监督与困难负例

正例–未标注学习表明, 未观察到正标签并不自动构成可靠负标签 [4, 8]; 去偏对比学习也揭示了假负例对表示目标的扭曲 [2]。超边预测中的困难负采样同样说明负例构造会改变训练信号 [3]。这些工作通常估计未标注样本的语义状态。本文采用更窄的立场: 只识别同时拥有负标签和完整最短答案路径成员资格的候选, 并校准其损失强度, 不把结构可达性改写成语义正标签。

2.3 路径派生监督

已有研究从答案可达路径构造检索监督, 或显式学习信息量更高的路径 [1, 5, 13]。本文关注此前较少被隔离的选择效应: 当训练过程只选择一条最短路径时, 其他等长最短路径上的转移可能被负采样。我们不枚举所有路径, 也不把所有最短路径转移一律标正, 而是仅对实际进入损失的冲突负例实施最小干预。

3 路径监督冲突与最小干预

3.1 完整路径判据

对问题 q , 令 S_q 和 A_q 分别为主题实体集合与正确答案实体集合。确定性超图以无向 incidence graph G_I 表示: 实体节点与事实节点相连; 一个候选转移 $t = (v, f, u)$ 表示从实体 v 经事实 f 到实体 u , 消耗两条 incidence edge。令 $d_I(x, y)$ 为 G_I 上的无权最短距离。

定义 1 (路径一致负例). 设 N_q 是原训练流程为问题 q 实际采样的负例集合。若 $t = (v, f, u) \in N_q$, 且存在 $(s, a) \in S_q \times A_q$ 满足

$$d_I(s, v) + 2 + d_I(u, a) = d_I(s, a), \quad (1)$$

则称 t 为路径一致负例, 并记所有此类转移构成 $D_q \subseteq N_q$ 。

式 (1) 检查的是完整主题–答案最短路径, 而不是局部朝答案靠近。仅有 $d_I(u, a) < d_I(v, a)$ 并不充分, 因为到达 v 的前缀可能已经绕远。实现中先从主题实体计算有界最短路径树, 再在最短路径有向无环结构上判断候选; 判据只扫描已经采样的负例, 不枚举组合候选空间。




Figure 1: 真实训练样例中的监督冲突。橙色转移没有进入被选路径, 却属于另一条完整等长最短答案路径。本文保留其原负标签, 只调整其损失权重。

图 1 不是人工构造的示意图, 而是按发布顺序从正式训练候选中确定性抽取的首个冲突样例。问题询问“哪些作曲家与 Giancarlo Santi 从事同一类型”, 其中一个正确答案是 Ennio Morricone。原流程选中的最短路径经由电影 *The Return of Clint the Stranger* 到达该答案; 另一条等长最短路径先由 Giancarlo Santi 到达类型 *Spaghetti Western*, 再经同一电影到达 Ennio Morricone。前一段“Giancarlo Santi → 事实节点 → Spaghetti Western”被原负采样器实际选中, 却满足 $0 + 2 + 2 = 4$ 的完整距离等式。该案例说明冲突来自训练数据的真实交互, 而非仅在理论候选空间中存在; 它仍不构成语义正标签的人工判定。

3.2 加权目标与三个策略

对训练候选 i 的原二元标签 $y_i \in \{0, 1\}$ 和模型 $\text{logit } z_i$, 定义

$$w_i(\lambda) = \begin{cases} \lambda, & i \in D_q, \\ 1, & \text{其他候选}, \end{cases} \quad \lambda \in [0, 1]. \quad (2)$$

一个 batch B 的损失为

$$\mathcal{L}_B(\lambda) = \frac{\sum_{i \in B} w_i(\lambda) \text{ BCEWithLogits}(z_i, y_i)}{\sum_{i \in B} w_i(\lambda)}. \quad (3)$$

分母使用权重和, 因此 $\lambda = 0.00$ 与删除 D_q 后对剩余样本求均值严格等价, $\lambda = 1.00$ 则与原 mean BCE 的数值和梯度严格等价。当 $\lambda = 0.00$ 且一个随机 batch 全部来自 D_q 时, 该 batch 不含有效监督; 实现会跳过其反向传播和优化器更新, 避免 Adam 动量在零梯度下仍改变参数。

正式主实验只比较三种策略。**策略 1** 是原始基线, 即所有候选权重均为 1.00。**策略 2** 是匹配随机对照: 对每个问题从全部已采样负例中均匀无放回选择恰好 $|D_q|$ 个, 抽样不查看路径身份, 并赋予与最终方法相同的权重。随机集合可能偶然与 D_q 重合, 因而该对照对策略 3 是保守的。**策略 3** 使用路径判据定位 D_q , 并赋予验证集冻结的 λ_D^* 。三者共享同一候选集合、特征、模型架构、初始化协议和训练配置; 因此策略 2 专门排除“只因减少了相同数量的负监督”这一解释。

每个领域从固定网格 $\{0.00, 0.10, 0.25, 0.50, 0.75, 1.00\}$ 中最大化验证集 Answer-Path MRR。若精确并列, 则选择较大的 λ , 优先更接近原基线。最终方法的名称和复杂度服从实验: 只有中间权重表现出稳定额外收益时才保留软加权; 否则按奥卡姆剃刀采用路径一致负例屏蔽。

4 实验

4.1 数据、图与官方检索器组件

我们使用 WikiTopics_QE 的 11 个领域, 以及发布的自然语言问题和结构化三跳查询。主题实体直接取自结构化查询 $(e, (r_1, r_2, r_3))$ 中的 e , 答案实体取自 benchmark ground truth; 答案仅用于训练监督和评价, 不进入推理候选生成或打分特征。通过冻结的 Wikidata 英文标签快照进行结构化查询与 NLG 对齐, 共得到 269,286 条对齐查询, 其中 263,295 条满足检索实验的图可达和实体映射条件。

我们按官方数据准备逻辑, 将训练图与测试推理上下文组成传导式图, 再把同一头实体的高元事实确定性重建为一个事实节点。实体身份始终使用 Wikidata QID; 文本标签仅作为编码器输入, 避免同名实体被错误合并。检索器复用 HyperRetriever 的本地 GTE-large-en-v1.5 表示、30 维 DDE 结构编码以及 $4126 \rightarrow 256 \rightarrow 1$ 的两层 MLP。GTE 使用最后隐层的 CLS 表示并做 L_2 归一化。训练采用 Adam, 学习率 0.0001, batch size 32、最多 50 个 epoch, 并在候选级分层内部验证集上按 patience 10 早停。

推理阶段从已知主题实体出发, 最多扩展三跳, 并只依据冻结 GTE 的问题相似度构造宽度为 32 的固定语义 beam; 候选生成不读取答案、不使用训练后 MLP 分数, 也不使用可调阈值。所有策略对完全相同的固定候选打分, 排序键为 MLP 原始 logit, 分数并列时按转移字典序稳定排序。

4.2 指标与统计协议

主指标为 Answer-Path MRR。对问题 q , 将候选转移按检索分数降序排列, 令 r_q 为最小的 k , 使前 k 个转移组成的子图能够连接任一主题实体与任一正确答案实体; 若始终不可达, 则 $RR_q = 0$, 否则 $RR_q = 1/r_q$ 。Answer-Path MRR 为所有问题 RR_q 的均值。次指标为 Reach@10, 即前 10 个转移是否已经形成主题—答案路径; 附录同时给出 Reach@5。

训练和比较使用共享随机种子 42–46。对每个问题先在五个种子间平均, 再进行 10,000 次 query-level paired bootstrap; 跨领域结果采用领域等权宏平均, 不把同一问题的不同种子当作独立样本。所有 λ_D^* 只由验证集确定, 测试集在冻结选择文件后才生成候选和评估。

4.3 路径一致负例是否真实进入训练

五个种子的实际训练候选共包含 9,860,170 个采样负例, 其中 452,522 个满足完整路径条件, 占 4.59%。按领域等权统计, 至少在一个种子中受到影响的问题比例为 59.03%。图 2 展示 11 个领域的负例级冲突率与问题级覆盖率; 附录表 2 给出精确计数。二者回答不同问题: 前者衡量损失中冲突监督的浓度, 后者衡量该现象波及多少训练问题。

4.4 主检索结果

表 1 报告独立测试集上的五种子均值。领域等权宏平均下, 策略 1、策略 2 和策略 3 的 Answer-Path MRR 分别为 6.09%、6.09% 和 6.31%; Reach@10 分别为 12.39%、12.35% 和 12.88%。策略 3 相对策略 1 的 MRR 差值为 0.23 个百分点, 95% CI 为 $[0.20, 0.26]$; Reach@10 差值为 0.49 个百分点, 95% CI 为 $[0.42, 0.55]$ 。

相对匹配随机对照, 策略 3 的 MRR 差值为 0.23 个百分点, 95% CI 为 $[0.19, 0.26]$; Reach@10 差值为 0.52 个百分点, 95% CI 为 $[0.46, 0.58]$ 。这一比较把“降低多少负监督”与“降低哪些负监督”分离开: 只有策略 3 相对策略 2 的配对区间支持差异




Figure 2: 路径一致负例在 11 个领域中的发生率。所有统计均来自实际进入训练的数据，而非枚举出的潜在候选。

时，收益才能归因于路径定位信息，而不是单纯减少损失质量。

四个配对区间的下界均大于零。正式结果因此同时支持两个结论：降低路径一致负例的监督强度优于保留原负权重，而且路径定位优于等量随机降权。收益并非由减少相同数量的负监督自动产生。

验证集最终选择了 9 个 $\lambda_D = 0.00$ 领域、1 个中间权重领域和 1 个 $\lambda_D = 1.00$ 领域。结果表明硬屏蔽是主要但并非普遍的最简选择：一个领域需要软加权，另一个领域保留原基线。附录表 3 给出全部冻结选择；我们不使用测试结果反向修改网格或判定规则。

4.5 最短路径选择敏感性

单路径监督还可能依赖“恰好选择了哪一条等长最短路径”。我们仅对确实存在多条等长最短答案路径的测试问题构造三个固定变体，使用种子 2718、3141 和 5772 改变 shortest-path DAG 中前驱的稳定顺序；不枚举指数数量的路径。每个变体分别训练策略 1 与策略 3。统计时先在每个变体内平均五个共享训练种子，再对三个变体均值报告 Answer-Path MRR、Reach@10 的均值、标准差和范围。

图 3(a) 汇总策略 3 相对策略 1 和策略 2 的逐领域 MRR 差值，图 3(b) 比较路径选择变体间的波动。领域等权平均的 MRR 标准差由策略 1 的 0.04% 变为策略 3 的 0.05%，平均范围由 0.10% 变为 0.12%。策略 3 没有降低路径择一波动，因而“降权会减少 tie-breaking 任意性”这一更强机制解释未获支持。另一方面，两种策略的平均范围都不超过 0.12 个百分点，说明主结论对三个固定路径变体的绝对波动较小，而不是策略 3 比策略 1 更稳定。

5 局限与结论

本文有四项边界。第一，路径一致性是结构性质，不是语义真值；满足式 (1) 的候选仍可能缺少回答问题所需的语义信息。第二，我们有意隔离 Retriever 训练，不调用生成器，因此不评价端到端生成式问答质量。第三，最短路径判据依赖观测图的实体对齐、事实覆盖和建图质量；图中缺失或错误的事实会改变距离。第四，正式验证集中在 WikiTopics 的 11 个领域，尚不能外推到监督定义不同的第二数据集。

在这些限制内，本文识别出单路径弱监督中的一个可复核冲突：部分实际采样负例同时位于完整最短答案路径上。我们用一领域级权重校准其损失强度，不改标签、不增模型参数，

也不改变推理。正式 Retriever-only 实验中，策略 3 相对策略 1 将领域等权 Answer-Path MRR 提高 0.23 个百分点、Reach@10 提高 0.49 个百分点；相对策略 2 的对应增益为 0.23 和 0.52 个百分点，四个配对置信区间均排除零。验证选择在多数领域简化为硬屏蔽，但仍保留一个软加权领域和一个原基线领域。路径变体实验显示绝对波动较小，却没有显示策略 3 比策略 1 更稳定。综合而言，正式证据支持按路径位置降低冲突负监督，也限制了关于 tie-breaking 稳健性的主张。

References

- [1] Alberto Cattaneo, Carlo Luschi, and Daniel Justus. 2025. Ground-Truth Subgraphs for Better Training and Evaluation of Knowledge Graph Augmented LLMs. arXiv:2511.04473 [cs.LG]
- [2] Ching-Yao Chuang, Joshua Robinson, Lin Yen-Chen, Antonio Torralba, and Stefanie Jegelka. 2020. Debaised Contrastive Learning. In *Advances in Neural Information Processing Systems*, Vol. 33. 8765–8775. <https://proceedings.neurips.cc/paper/2020/hash/63c3ddcc7b23daa1e42dc41f9a44a873-Abstract.html>
- [3] Zhenyu Deng, Tao Zhou, and Yilin Bi. 2026. Hard Negative Sampling in Hyper-edge Prediction. *IEEE Transactions on Network Science and Engineering* 13 (2026), 4833–4846. doi:10.1109/TNSE.2025.3634750
- [4] Charles Elkan and Keith Noto. 2008. Learning Classifiers from Only Positive and Unlabeled Data. In *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 213–220. doi:10.1145/1401890.1401920
- [5] Shengxiang Gao, Chao Lei, Jey Han Lau, and Jianzhong Qi. 2026. PathISE: Learning Informative Path Supervision for Knowledge Graph Question Answering. arXiv:2605.10791 [cs.AI]
- [6] Xiaoxin He, Yijun Tian, Yifei Sun, Nitesh V. Chawla, Thomas Laurent, Yann LeCun, Xavier Bresson, and Bryan Hooi. 2024. G-Retriever: Retrieval-Augmented Generation for Textual Graph Understanding and Question Answering. In *Advances in Neural Information Processing Systems*, Vol. 37. doi:10.52202/079017-4224
- [7] Vladimir Karpukhin, Barlas Oguz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. 2020. Dense Passage Retrieval for Open-Domain Question Answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*. 6769–6781. doi:10.18653/v1/2020.emnlp-main.550
- [8] Ryuichi Kiryo, Gang Niu, Marthinus C. du Plessis, and Masashi Sugiyama. 2017. Positive-Unlabeled Learning with Non-Negative Risk Estimator. In *Advances in Neural Information Processing Systems*, Vol. 30. <https://proceedings.neurips.cc/paper/2017/hash/7cce53cf90577442771720a370c3c723-Abstract.html>
- [9] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Kuttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. 2020. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In *Advances in Neural Information Processing Systems*, Vol. 33. 9459–9474. <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>
- [10] Mufei Li, Siqi Miao, and Pan Li. 2025. Simple Is Effective: The Roles of Graphs and Large Language Models in Knowledge-Graph-Based Retrieval-Augmented Generation. In *International Conference on Learning Representations*. arXiv:2410.20724 <https://openreview.net/forum?id=jvkuZZ04O7>
- [11] Wen-Sheng Lien, Yu-Kai Chan, Hao-Lung Hsiao, Bo-Kai Ruan, Meng-Fen Chiang, Chien-An Chen, Yi-Ren Yeh, and Hong-Han Shuai. 2026. HyperRAG: Reasoning N-ary Facts over Hypergraphs for Retrieval Augmented Generation. In *Proceedings of the ACM Web Conference 2026*. 2465–2476. doi:10.1145/3774904.3792710
- [12] Haitian Sun, Tania Bedrax-Weiss, and William W. Cohen. 2019. PullNet: Open Domain Question Answering with Iterative Retrieval on Knowledge Bases and Text. In *Proceedings of EMNLP-IJCNLP*. 2380–2390. doi:10.18653/v1/D19-1242
- [13] Jing Zhang, Xiaokang Zhang, Jifan Yu, Jian Tang, Jie Tang, Cuiping Li, and Hong Chen. 2022. Subgraph Retrieval Enhanced Model for Multi-hop Knowledge Base Question Answering. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics*. 5773–5784. doi:10.18653/v1/2022.acl-long.396

A 可复现协议与 provenance

代码以官方 HyperRAG 提交为冻结上游，实验配置、标签快照、数据校验、队列命令、物理 GPU、Python/PyTorch/CUDA 环境、Git 提交、随机种子、 λ 、checkpoint 和逐问题指标均随运行产物保存。原始产物经聚合 JSON/CSV 自动生成 LaTeX 宏、表格和 PDF/SVG 图；正文不手抄实验数字。实体节点以 QID 为身份、标签只用于文本编码。该约束尤其重要，因为不同 QID 可

Table 1: 独立测试集上的正式 **Retriever-only** 结果。每个单元格为五个共享种子的均值；粗体表示同一领域、同一指标下三个策略中的最优值。 λ_D^* 只由验证集 **Answer-Path MRR** 冻结。

领域	λ_D^*	Answer-Path MRR (%)			Reach@10 (%)		
		策略 1	策略 2	策略 3	策略 1	策略 2	策略 3
art	0.00	3.50	3.45	3.71	7.23	7.20	7.61
award	0.10	5.19	5.21	5.12	12.08	12.10	12.13
edu	0.00	7.01	7.05	7.53	13.47	13.57	14.28
health	0.00	7.22	7.26	7.74	16.16	16.19	17.35
infra	0.00	14.95	14.87	15.12	29.00	28.69	29.26
loc	0.00	7.61	7.73	7.80	14.36	14.30	14.77
org	1.00	1.26	1.26	1.26	2.94	2.94	2.94
people	0.00	9.66	9.62	9.69	18.65	18.55	18.71
sci	0.00	5.22	5.20	6.12	12.19	12.08	14.36
sport	0.00	2.79	2.76	2.81	5.36	5.26	5.31
tax	0.00	2.52	2.55	2.55	4.85	5.00	4.90
领域等权宏平均	–	6.09	6.09	6.31	12.39	12.35	12.88




Figure 3: 主结果与路径选择敏感性。(a) 路径定位降权是否优于原基线及等量随机对照；(b) 它是否降低单路径选择带来的训练任意性。

能共享同一英文标签，若以标签作为节点身份会错误合并实体。

候选 beam 宽度在正式扫描前只用艺术领域验证集做一次 10 与 32 的 P0 覆盖率比较：二者分别覆盖 13.10% (1,294/9,878) 和 21.92% (2,165/9,878) 的验证问题，因此冻结为 32，不继续搜索第三个宽度。 λ 网格、选择指标、五个训练种子、三个路径变体种子和 bootstrap 协议均在正式结果前冻结。历史结构代理产物保持只读，不与正式 Retriever-only 结果混写。

B 逐领域冲突发生率

Table 2: 五个训练种子中实际采样负例的逐领域路径一致冲突统计。

领域	采样负例	路径一致负例	比例 (%)	受影响问题 (%)
art	859,445	26,281	3.06	44.93
award	1,639,900	103,416	6.31	84.57
edu	846,250	49,808	5.89	67.16
health	1,435,195	62,180	4.33	67.22
infra	922,620	48,910	5.30	70.12
loc	581,265	12,237	2.11	62.45
org	704,355	60,460	8.58	70.31
people	725,525	12,218	1.68	38.60
sci	705,320	42,115	5.97	62.60
sport	654,245	5,918	0.90	31.94
tax	786,050	28,979	3.69	49.44

C 完整验证集权重选择

D 路径选择敏感性明细

E 历史结构诊断的定位

先前结构代理实验在约 90,000 个问题上观察到路径一致负例会真实进入采样，并发现硬屏蔽可能提高结构覆盖但伴随排序代价；其中一次端点实验的排序指标下降约 1.32 个百分点。该结果只用于提出研究问题和设计正式对照，不能通过重复试验被改写为成功，也不充当本文语义 Retriever 的主证据。正式结论只取决于本稿报告的 GTE+DDE+MLP Retriever-only 实验、验证集冻结选择与独立测试结果。

Table 3: 各领域在验证集上的 Answer-Path MRR (%)。粗体为按冻结规则选出的 λ_D^* ；精确并列时取更大的 λ 。

领域	λ_D^*	0.00	0.10	0.25	0.50	0.75	1.00
art	0.00	3.57	3.54	3.53	3.44	3.42	3.41
award	0.10	5.16	5.33	5.32	5.32	5.26	5.32
edu	0.00	7.36	7.18	7.07	6.95	6.86	6.81
health	0.00	7.82	7.71	7.46	7.36	7.35	7.19
infra	0.00	12.75	12.57	12.51	12.43	12.36	12.44
loc	0.00	6.48	6.44	6.41	6.39	6.39	6.41
org	1.00	0.78	0.82	0.85	0.85	0.84	0.87
people	0.00	10.43	10.38	10.31	10.28	10.26	10.20
sci	0.00	6.57	6.26	6.04	5.91	5.78	5.77
sport	0.00	2.29	2.26	2.26	2.24	2.27	2.25
tax	0.00	4.46	4.40	4.31	4.27	4.24	4.28

Table 4: 仅在存在多条等长最短答案路径的问题上统计的路径选择敏感性。范围为三个固定 tie-breaking 变体之间的最大值减最小值。

领域	问题数	策略 1 MRR	策略 3 MRR	策略 1 范围	策略 3 范围
art	9,460	3.03	3.29	0.02	0.09
award	9,630	5.35	5.32	0.13	0.15
edu	8,353	8.06	8.37	0.15	0.15
health	9,658	7.56	8.43	0.05	0.15
infra	8,851	15.06	15.33	0.11	0.03
loc	3,683	7.64	7.79	0.12	0.22
org	3,897	1.22	1.22	0.01	0.01
people	8,827	9.59	9.78	0.08	0.05
sci	8,718	6.17	6.60	0.18	0.20
sport	3,468	2.91	2.91	0.14	0.14
tax	7,108	2.55	2.58	0.07	0.11